Projekt 2
Hľadanie pokladu (2b)

Laura Fulajtárová

Fakulta informatiky a informačných technológií STU

xfulajtarova@stuba.sk

ID: 120782

UI – Utorok 14:00

31.10.2023

Contents

1 Parametre môjho počítača

- Processor AMD Ryzen 7 5800H with Radeon Graphics 3.20 GHz
- Installed RAM 16.0 GB (13.9 GB usable)
- System type 64-bit operating system, x64-based processor

2 Implementačné prostredie

Rozhodla som sa použiť Python ako implementačné prostredie kvôli jeho jednoduchosti, prirodzenému čitateľnému kódu, rozsiahlemu ekosystému knižníc a funkcií, čo umožňuje rýchle a efektívne vývojové práce. Python je ideálny pre implementáciu rôznych algoritmov vrátane evolučných algoritmov, pričom minimalizuje komplikácie spojené s programovaním, takže môžem sústrediť svoju pozornosť na samotný algoritmus a jeho správne fungovanie.

3 Prehľad súborov

3.1 main.py

V tomto súbore sa nachádza používateľské rozhranie a hlavná logika pre spustenie hry. Používateľ si môže nastaviť svoje preferencie, vrátane veľkosti mriežky, počtu jedincov v populácii, maximálneho počtu populácie, úrovne mutácie, typu selekcie a ďalšie. Po nastavení týchto preferencií sa hra spustí a zobrazia sa výsledky riešenia.

3.2 game.py

Tento súbor obsahuje celkovú logiku hry. Vytvára populáciu jedincov, spúšťa virtuálny stroj pre každého jedinca a hľadá najlepšie riešenie hry pomocou evolučného algoritmu.

3.3 individual.py

Slúži na uchovávanie údajov o jednotlivcoch, nazývaných chromozómy. Objekt v tomto súbore uchováva informácie o pôvodných génoch jedinca, krokoch generovaných virtuálnym strojom, počte nájdených pokladov, hodnote fitness a hernú dosku po vykonaní krokov.

3.4 moves.py

Program generuje pohyb hľadateľa na mriežke v štyroch základných smeroch: vľavo, vpravo, hore a dole. Ak náhodou narazí na pozíciu s pokladom, program tento poklad odstráni z herného plánu a označí ho za nájdený.

3.5 printing.py

Tento súbor je určený na výpis a zobrazovanie herného plánu, animácie na ňom a grafiku pre sledovanie vývoja hodnôt fitness pre všetky populácie.

3.6 testing.py

V tomto súbore boli vykonané testy a porovnania výsledkov programu. Umožňuje opakované spustenie programu s rôznymi nastaveniami pre oba typy selekcie. Sú tu zobrazované grafy, ktoré ukazujú, ktoré prípady boli riešené a ktoré nie v rôznych generáciách, a tiež celkový čas behu programu.

4 Riešený problém

Našou hlavnou úlohou bolo vytvoriť hru, v ktorej sme hľadali poklady na dvojrozmernej mriežke. Hľadač sa mohol pohybovať v štyroch základných smeroch: hore, dole, vpravo a vľavo. Naša úloha spočívala v tom, že sme mali obmedzený počet krokov, v ktorých sme sa snažili nájsť čo najviac pokladov. Túto úlohu sme riešili pomocou evolučného programovania nad virtuálnym strojom.

Virtuálny stroj mal za úlohu generovať postupnosť náhodných krokov, ktoré jednotlivec v populácii vykonal. Títo jedinci boli zoskupení do populácie, ktorá sa vyvíjala prostredníctvom selekcie, kríženia, mutácie a elitarizmu. Každého jedinca sme ohodnotili pomocou fitness hodnoty, ktorá nám indikuje, kvalitu jednotlivca.

Program má byť ukončený v prípade, že hľadač našiel všetky poklady alebo keď sme dosiahli maximálny počet generácií.

4 Evolučný algoritmus

Evolučný algoritmus predstavuje fascinujúci prístup k riešeniu problémov, ktorý čerpá inšpiráciu z prírody, konkrétne z Darwinovej evolúcie a Mendelovej genetiky. Jeho cieľom je nájsť a zlepšiť najlepšie možné riešenie pre daný problém. Tento proces sa uskutočňuje v niekoľkých krokoch:

1. Inicializácia: Začíname vytvorením prvej populácie náhodných jedincov. Každý jedinec v populácii má svoj chromozóm, ktorý je zložený z génov.
2. Evaluácia: Pre každého jedinca v populácii určíme jeho "fitness" alebo schopnosť riešiť daný problém. Táto hodnota ovplyvňuje, ktorí jedinci budú vybraní pre ďalší vývoj.
3. Možné ukončenie: Po určitom čase alebo po dosiahnutí požadovanej úrovne fitness posúdime, či sme spokojní s populáciou a jedincami. Ak áno, ukončíme algoritmus. V opačnom prípade pokračujeme v ďalšom vývoji populácie.
4. Selekcia: Najlepší jedinci s najvyššou "fitness" prežijú a budú základom pre budúcu generáciu.
5. Variácia: Na vytvorenie novej generácie použijeme týchto lepších jedincov a kombinujeme ich genetický materiál napríklad cez procesy ako crossover a mutácia, čo nám umožňuje objavovať nové možnosti.
6. Návrat k evaluácii: S novou populáciou, ktorá má potenciálne vyššiu "fitness", sa vrátime k evaluácii. Tento krok sa opakuje, kým nedosiahneme požadované výsledky alebo nedosiahneme stanovený maximálny počet generácií.

Evolučný algoritmus nám teda umožňuje postupne zlepšovať riešenia v rámci populácie, pričom sa inšpiruje prírodnými procesmi evolúcie a genetiky, a to všetko s cieľom nájsť čo najlepšie riešenie daného problému.

5 Reprezentácia údajov

5.1 Populácia

V rámci evolučného algoritmu je populácia reprezentovaná ako kolekcia jednotlivcov, ktorí sú v tomto kontexte známi ako chromozómy.

5.2 Chromozóm

Chromozóm je jedinečným zástupcom v populácii, a preto mu venujem osobitný objekt, v ktorom uchovávam všetky relevantné informácie. To zahŕňa hodnoty, fitness, počet nájdených pokladov, počet krokov, ktoré vykonal, a informácie o jeho pohybe v rámci mriežky po vykonaní pohybov.

5.3 Gén

Chromozóm je rozdelený na 64 bytov, pričom každých 8 bitov tvorí jeden gén. Tieto gény obsahujú informácie, ktoré určujú vlastnosti a správanie jednotlivca. Gény sú základnými stavebnými jednotkami chromozómov a ovplyvňujú vývoj a výsledky jednotlivcov v populácii.

6 Virtuálny stroj

Náš virtuálny stroj disponuje 64 pamäťovými bunkami, pričom každá má veľkosť 1 byte, a rozumie štyrom základným inštrukciám: zvýšenie hodnoty bunky, zníženie hodnoty bunky, skok na konkrétnu adresu a výpis na základe hodnoty bunky. Inštrukcie majú tvar 00XXXXXX (increment), 01XXXXXX (decrement), 10XXXXXX (jump) a 11XXXXXX (write), kde XXXXXX reprezentuje adresu bunky. Výstup inštrukcií závisí od hodnoty bunky: P pre 1-2, H pre 3-4, D pre 5-6 a L pre 7-8. Program okrem výstupu poskytuje aj informácie o pohyboch, ktoré vykonal. Program sa ukončí, ak nájde všetky poklady, vyjde z mriežky alebo vykona 500 krokov. Vytvorí objekt pre daný chromozóm s údajmi ako je počet nájdených pokladov, gény, fitness, kroky a mriežka. Fitness funkcia závisí od počtu nájdených pokladov a vykonaných krokov, je reprezentovaná vzorcom: f=2/(počet krokov +1)+5*počet nájdených pokladov. Program bol zjednodušený na pseudo program, pre jeho úplné znenie pozrite súbor *game.py*. Pre jednotlivé pohyby na mriežke pozrite súbor *moves.py*.

Adresa:	000000	000001	000010	000011	000100	000101	000110	...
Hodnota:	00000000	00011111	00010000	01010000	00000101	11000000	10000100	...

```
def virtual_machine(individual, board, board_size, treasure_count):
    board_copy = board.copy()
    moves_list = []
    individual_copy = individual.copy()
    out_of_bounds = False
    treasure_found_num = 0
    register_index = 0
    for i in range(500):
        if register_index <= 63:
            opcode = individual[register_index][:2]
            register_value = individual[register_index][2:]

            if opcode == "00":
                increment

            elif opcode == "01":
                decrement

            elif opcode == "10":
                jump

            elif opcode == "11":
                new_register_index = int(register_value, 2)
                new_register_value = individual[new_register_index]
                ones_count = new_register_value.count("1")
                if ones_count <= 2:
                    up
                elif ones_count <= 4:
                    down
                elif ones_count <= 6:
                    left
                else:
                   right
                if treasure_found:
                    treasure_found_num += 1
                register_index += 1
        else:
            register_index = 0

        if out_of_bounds or treasure_found_num == treasure_count:
            break

    fitness = 2 / (len(moves_list) + 1) + 5 * treasure_found_num
    individual_object = Individual(
        individual_copy, fitness, moves_list, treasure_found_num, board_copy)

    if treasure_found_num == treasure_count:
        global solution_individual
        solution_individual = individual_object

    return individual_object
```

7 Tvorba populácie

7.1 Prvá populácia

Prvú populáciu vytvárame vytvorením náhodných génov pre určený počet jedincov v populácii. Každý gén je reprezentovaný 64 bytmi. Následne týchto jedincov vkladáme do virtuálneho stroja, ktorý vytvára objekty s relevantnými údajmi pre každého jedinca. Tieto objekty potom ukladáme do spoločného zoznamu, ktorý vytvorí danú populáciu.

```
def make_first_generation(
    board, individual_count, random_values_for_individuals, board_size, treasure_count
):
    generation_list_object = []
    global solution_individual

    for i in range(individual_count):
        if solution_individual is None:
            board_copy = board.copy()
            individual_values = vm_create_random_values(random_values_for_individuals)
            individual_object = virtual_machine(
                individual_values, board_copy, board_size, treasure_count)
            generation_list_object.append(individual_object)

    return generation_list_object
```

7.2 Ostatné populácie

Začíname tým, že zoradíme jedincov v populácii na základe ich fitness hodnôt. Potom z tejto zoradenej populácie vyberáme elitných jedincov, ktorých automaticky prenesieme do novej populácie.

Pre vytvorenie ďalších jedincov využívame selekciu, či už pomocou metódy rulety alebo turnaja. Z týchto vybraných rodičov potom vytvárame nových potomkov pomocou procesu kríženia , kde kombinujeme genetický materiál od oboch rodičov, čím vytvárame nových jedincov.

Títo noví jedinci sú následne podrobení mutáciám s určitou pravdepodobnosťou, čo pridáva variabilitu do populácie. Ak je populácia plná, presunieme ju do ďalšieho kola, v ktorom opakujeme tento proces.

Celý tento cyklus pokračuje, kým nenájdeme optimálne riešenie, alebo nedosiahneme maximálny počet generácií. Týmto spôsobom evolučný algoritmus postupne zlepšuje populáciu a hľadá najlepšie možné riešenia pre daný problém.

```
while solution_individual is None and generation_num < max_generations:
        generation_num += 1

        generation_list_object.sort(key=lambda x: x.fitness, reverse=True)

        best_fintness_individuals.append(generation_list_object[0].fitness)

        elite_individuals = []
        elite_individuals = copy.deepcopy(
            generation_list_object[:elite_individual_count]
        )

        subelite_individuals = []
        if selection_type == 1:
            subelite_individuals = roulette_wheel(
                copy.deepcopy(generation_list_object),
                individual_count,
                elite_individual_count,
            )
        else:
            subelite_individuals = tournament(
                copy.deepcopy(generation_list_object),
                individual_count,
                elite_individual_count,
            )

        mutation_list = []
        mutation_list = mutation(subelite_individuals, mutation_probability)

        subelite_list_objects = make_other_generations(
            mutation_list, board_copy, board_size, treasure_count
        )

        population_list_object = []
        population_list_object = copy.deepcopy(elite_individuals)
        population_list_object.extend(subelite_list_objects)

        generation_list_object = population_list_object
```

7.3 Selekcia

Selekcia je výber lepších jedincov na základe ich úspešnosti, čím zvyšuje ich šancu na prežitie a ďalšiu generáciu. Pomáha vylepšovať celkovú kvalitu populácie.

7.3.1 Ruleta

Metóda rulety vyberá jedincov do podpopulácie (subelite). Rozpočítame fitness jedincov, vytvoríme pravdepodobnosti výberu, a na základe nich vyberáme rodičov a tvoríme potomkov. Potomkovia sú pridaní do subpopulácie.

```
def roulette_wheel(generation_list_object, individual_count, elite_individual_count):
    subelite_individuals = []

    total_fitness = sum(individual.fitness for individual in generation_list_object)
    selection_probabilities = [
        individual.fitness / total_fitness for individual in generation_list_object
    ]
```

```
    while len(subelite_individuals) != (individual_count - elite_individual_count):
        parent1 = random.choices(generation_list_object, selection_probabilities)[0]
        parent2 = random.choices(generation_list_object, selection_probabilities)[0]

        first_child, second_child = crossover(parent1.value, parent2.value)

        if first_child not in subelite_individuals and len(
            subelite_individuals
        ) + 1 <= (individual_count - elite_individual_count):
            subelite_individuals.append(first_child)
        if second_child not in subelite_individuals and len(
            subelite_individuals
        ) + 1 <= (individual_count - elite_individual_count):
            subelite_individuals.append(second_child)

    return subelite_individuals
```

7.3.2 Turnament

V prípade funkcie tournament_winner vytvárame náhodný turnajný zoznam a vyberáme víťaza na základe fitness.

Funkcia tournament vytvára náhodne veľké turnaje, kým nedosiahneme požadovaný počet jedincov pre subpopuláciu. V každom turnaji vyberáme rodičov na základe ich fitness pomocou funkcie tournament_winner, a títo rodičia sú následne využití na vytvorenie potomkov. Potomkovia sú pridaní do subelite podľa stanovených kritérií.

```
def tournament_winner(generation_list_object, size_of_tournament):
    tournament_list = []

    for _ in range(size_of_tournament):
        tournament_list.append(random.choice(generation_list_object))
    tournament_list.sort(key=lambda x: x.fitness, reverse=True)
    winner = tournament_list[0]
    return winner


def tournament(generation_list_object, individual_count, elite_individual_count):
    subelite_individuals = []

    size_of_tournament = random.randint(2, 5)
    while len(subelite_individuals) != (individual_count - elite_individual_count):
        parent_1 = tournament_winner(generation_list_object, size_of_tournament)
        parent_2 = tournament_winner(generation_list_object, size_of_tournament)

        while parent_1 == parent_2:
            parent_2 = tournament_winner(generation_list_object, size_of_tournament)

        parent_1_values = parent_1.value
        parent_2_values = parent_2.value

        first_child, second_child = crossover(parent_1_values, parent_2_values)

        if first_child not in subelite_individuals and len(
            subelite_individuals
        ) + 1 <= (individual_count - elite_individual_count):
            subelite_individuals.append(first_child)
        if second_child not in subelite_individuals and len(
            subelite_individuals
        ) + 1 <= (individual_count - elite_individual_count):
            subelite_individuals.append(second_child)

    return subelite_individuals
```

7.4 Reprodukcia

Reprodukcia v evolučných algoritmoch slúži na vytvorenie nových jedincov v populácii pomocou kríženia (crossover) a mutácie existujúcich jedincov. Týmto spôsobom sa kombinujú genetické vlastnosti a vytvárajú sa potomkovia, čím sa postupne zlepšuje celková kvalita populácie a hľadá najlepšie riešenia pre daný problém.

7.4.1 Crossover

Táto funkcia dostáva dvoch rodičov ako vstupné parametre a vykonáva kríženie tým spôsobom, že náhodne vyberie index, kde rozdelí genetický materiál oboch rodičov, a potom spojí tieto časti, čím vytvorí nových potomkov.

```python
def crossover(parent1, parent2):
    r_num = random.randint(1, 64)
    first_child = parent1[:r_num] + parent2[r_num:]
    second_child = parent2[:r_num] + parent1[r_num:]
    return first_child, second_child
```

7.4.2 Mutácia

Mutácia prebieha s pravdepodobnosťou, ktorú určuje používateľ, a ovplyvňuje zmenu genov a ich počet. Začíname výberom náhodných indexov génov na mutáciu podľa stanovenej pravdepodobnosti. Potom vybrané gény mutujeme pomocou XOR operácie na 3 bitoch. Mutovaných jedincov postupne pridávame do zoznamu a následne ho vrátime.

```python
def mutation(other_generation_list, mutation_probability):
    mutation_list = []

    for individual in other_generation_list:
        for j in range(mutation_probability):
            cell_index = random.randint(0, 63)
            cell = individual[cell_index]
            dec_byte = int(cell, 2)
            for k in range(3):
                mask = 1 << random.randint(0, 7)
                cell = dec_byte ^ mask
                dec_byte = cell
            individual[cell_index] = bin(cell)[2:].zfill(8)
        mutation_list.append(individual)

    return mutation_list
```

8 Používateľské rozhranie

Upravila som používateľské rozhranie vytvorením menu v termináli. Používateľ má teraz možnosť vybrať si, či chce použiť vopred definovanú mriežku zo zadania, vytvoriť vlastnú mriežku alebo ukončiť program. V prípade, že neukončí program, používateľ môže zadať rôzne údaje, ako je počet jedincov v populácii, počet náhodne inicializovaných génov pre jednotlivca, typ selekcie, elitarizmus, mutáciu, maximálny počet generácií a aj to, či chce zobraziť výstupy a jednoduchú animáciu simulácie pohybu hľadača na mriežke. Po vykonaní nám program taktiež zobrazí graf, ktorý opisuje fitness hodnotu najlepšieho jedinca v jednotlivej populácii. Týmto spôsobom sme pridali viac interakcie a prispôsobili program podľa potrieb používateľa.

8.1 Mriežka zo zadania

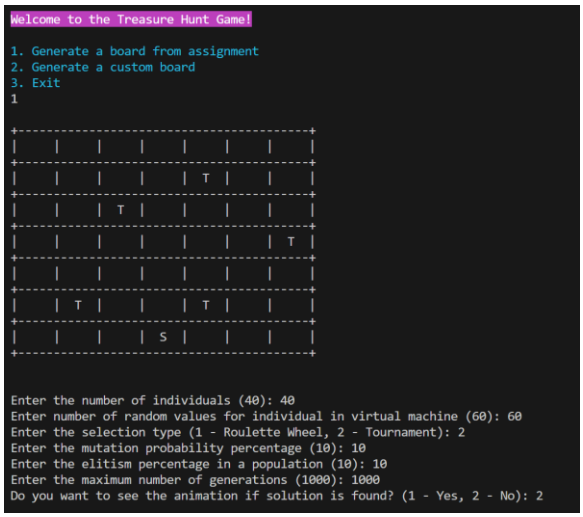

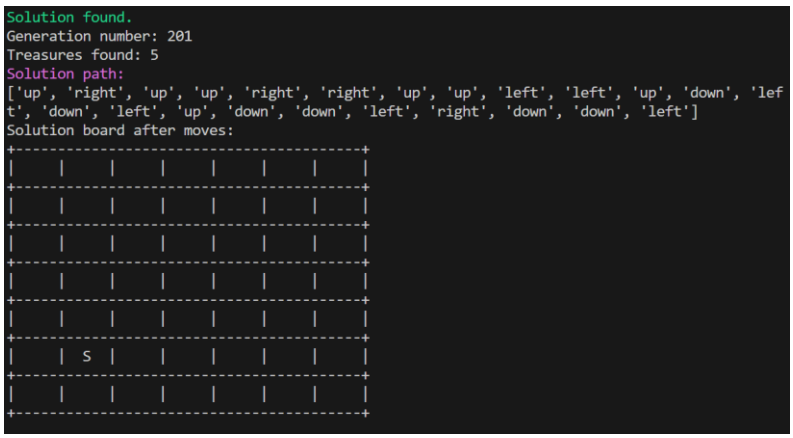

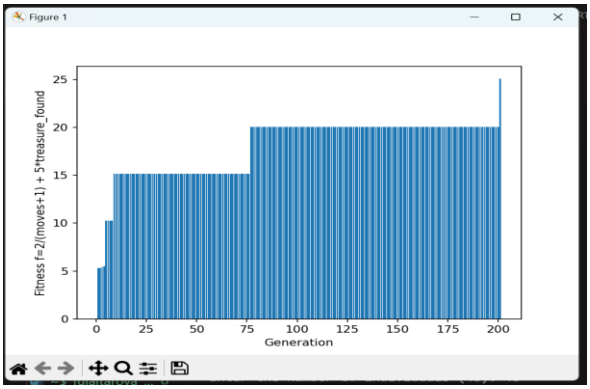

8.2 Používateľom vytvorená mriežka

```
1. Generate a board from assignment
2. Generate a custom board
3. Exit
2

Enter the board size: 3
+-------------+
|  1 |  2 |  3 |
+-------------+
|  4 |  5 |  6 |
+-------------+
|  7 |  8 |  9 |
+-------------+


Enter number of the starting point: 7
Enter the treasure indexes (separated by spaces): 1 3 5
+-------------+
|  T |    |  T |
+-------------+
|    |  T |    |
+-------------+
|  S |    |    |
+-------------+


Enter the number of individuals (40): 20
Enter number of random values for individual in virtual machine (60): 50
Enter the selection type (1 - Roulette Wheel, 2 - Tournament): 1
Enter the mutation probability percentage (10): 5
Enter the elitism percentage in a population (10): 10
Enter the maximum number of generations (1000): 100
Do you want to see the animation if solution is found? (1 - Yes, 2 - No): 2
```

```
Solution found.
Generation number: 26
Treasures found: 3
Solution path:
['up', 'right', 'left', 'up', 'right', 'down', 'up', 'right'
Solution board after moves:
+--------------+
|    |    |  S |
+--------------+
|    |    |    |
+--------------+
|    |    |    |
+--------------+
```

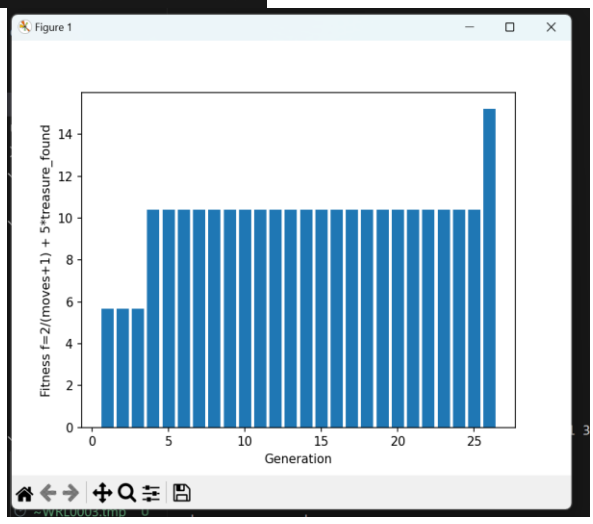

8.3 Animácia

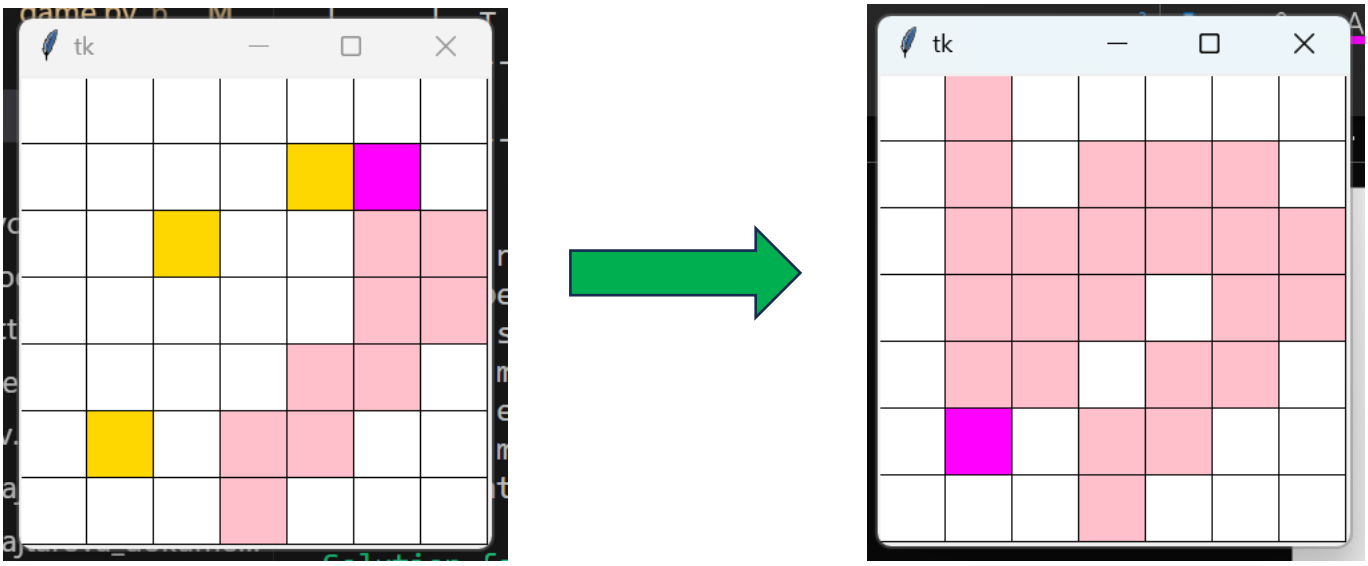

9 Zhodnotenie výsledkov

Vykonala som selekciu v populácii dvoma spôsobmi: pomocou metódy rulety a turnaja. Pre každý z týchto dvoch typov selekcie som spustila program 50-krát a získala priemerné výsledky. Zistila som, že tieto dva typy selekcie sa podobajú, a výsledné rozdiely sú skoro zanedbateľné.

Pokiaľ ide o počet nenájdených riešení, oba typy boli na tom rovnako. Avšak, ak sa pozrieme na nájdené riešenia a v akej populácii boli nájdené, vidíme, že turnajová selekcia dosahuje lepšie výsledky. Čo sa týka časovej náročnosti, ruleta trvala o 10 sekúnd dlhšie.

Na grafe sú na osi X uvedené poradové čísla jednotlivých testov a na osi Y je zobrazené, v ktorej generácii bolo riešenie nájdené alebo nenájdené. Nenájdené riešenia sú označené červenou farbou a nájdené zelenou. Pri výpočte priemeru som zahrnula všetky riešenia.

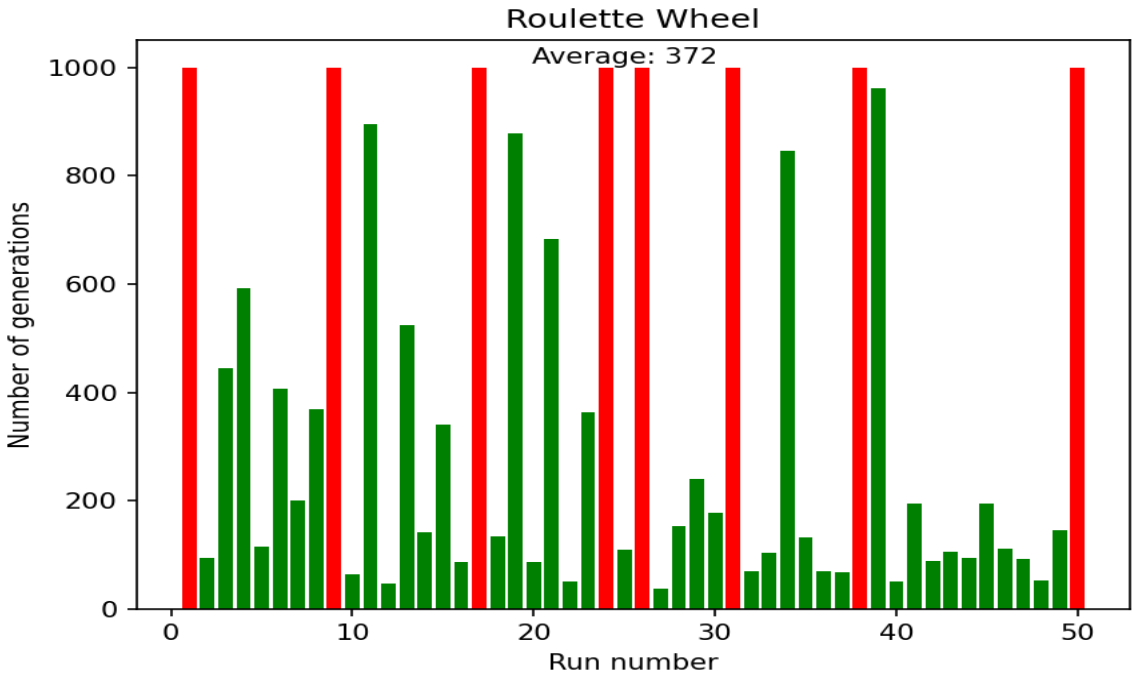

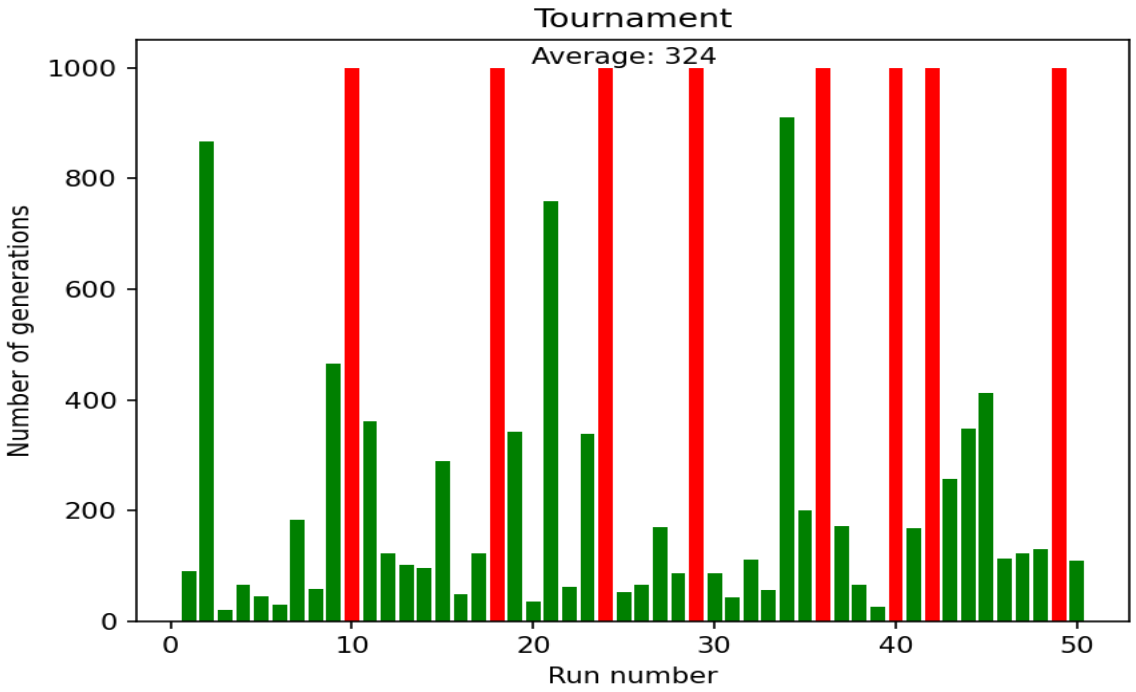


```
Roulette Wheel
Time: 66.01692008972168 s

Tournament
Time: 79.63804221153259 s
```

10 Možné vylepšenia

V snahe zlepšiť môj kód a optimalizovať ho, začnem identifikovaním miest, kde môžem zvýšiť jeho efektivitu. To znamená preskúmanie existujúceho algoritmu a použitie efektívnejších dátových štruktúr alebo algoritmických postupov. Zároveň zredukujem nepotrebný kód a odstránim zbytočné časti, ktoré neprinášajú hodnotu.

Rovnako dôležité je zvýšenie priestorovej efektivity kódu. Preskúmam, ako sa využíva pamäť, a pokúsim sa znížiť pamäťovú náročnosť tam, kde to bude možné.

Na záver, možnosti rozšírenia programu zahrňujú pridanie ďalších typov selekcií a mutácií. Môžem implementovať rôzne stratégie selekcie, a experimentovať s rôznymi spôsobmi mutácií genetického algoritmu. Týmto spôsobom by sme mohli dosiahnuť lepšie výsledky pri riešení problémov pomocou genetických algoritmov.

Použitá literatúra

1. https://www.youtube.com/watch?v=L--IxUH4fac&t=112s&ab_channel=Dr.ShahinRostami
2. http://www2.fiit.stuba.sk/~kapustik/poklad.html